
Why your plan needs a smarter reviewer

为什么写计划的模型，需要另一个（通常更强的）模型来 review ——
以及具体怎么做。

What's in here

- 01 **Why** 同一个模型，同一片盲区
- 02 **The receipt** 唯一错的小节，恰是唯一没测的
- 03 **Why stronger** 两个机制，不只是「更聪明」
- 04 **Where & How** 评审花在不可逆处；分屏、收敛、再写码
- 05 **Cheat sheet** 三条守则

01


The blind spot

同一个模型，同一片盲区

Same model, same blind spot

- 生成是展开，评审是证伪 —— 两种不同的能力。
- 自评和写作走同一条证据链：错的证据不会触发警报。

结论错了能改；证据错了，会一路带进代码。



02

The receipt

唯一错的小节，恰是唯一没测的

Only the untested part was wrong

01 证据密度和两处自我推翻值得保留。

02 一句 JSDoc 交叉引用被当成了「声明证据」。

03 唯独纯读文档那节，错了。

那条是把 JSDoc 里的一句错误交叉引用当成了声明证据。其余"实跑验证"的条目（marked 12 载荷、事件顺序）我抽查都站得住，唯独 webview 宿主 API 那节是纯读文档得来的，也正是唯一出错的一节。建议 §0.5

03

Why it is stronger

两个机制，不只是「更聪明」

Two mechanisms, not one

为什么是「更高智力」，而不只是「另一个模型」。

A 能力不对称

只有更强的模型能分辨「看起来有证据」和「真的有证据」。

B 失效模式不同

不同训练数据 → 幻觉与疏漏的分布不一样。交叉评审覆盖的是盲区。

执行模型

↻ 66轮 511步 💰 109M tok · 缓存命... deepseek-flash(max)

便宜、快

评审模型

* Cogitated for 5m 1s · done 18:52

贵、慢 · 只在刀口上

04

Where it pays off

评审花在不可逆处；分屏、收敛、再写码

Review the irreversible

- 不可逆、有安全边界、有下游依赖的决策 —— 必须外部评审。
- 反例：不要 review 每一行代码。


这条错了要返工，就 review 它。

一个提醒

计划里 §3 约束写的 `"render.ts` 是唯一 HTML 生成点
`""webview 不加载远程资源""`不用 `enableCommandUris` 这几条，是你手动评审时最值得盯的地方 — 这是整个 S2 唯一有真实安全后果的部分。


屏幕里的原话：「**这是整个 S2 唯一有真实安全后果的部分。**」

Split the screen, hire a reviewer



左: **DeepSeek** (执行 / 写 plan) • 右: **Opus 5** (评审)

评审员和你同目录，能自己读 plan、读代码、跑测试 —— 不用你贴上下文。



选型: 1M context 装得下整个 repo; high effort 值这几分钟。

05

Cheat sheet

三条守则

Converge, then code

按我们的流程，我先写 `docs/S2-plan.md`，然后跑外部评审（Claude + Codex），收敛后再动手。

要我现在开始写 S2 计划吗？

一句话启动

- 01 把流程**写进约定**（skill / AGENTS.md）—— AI 自己会拉评审，不用你提醒。
- 02 一句话启动： 看一下 DeepSeek 写的 S2-plan，给出评审意见
- 03 意见**编号落盘**： S2-CL-01... → plan 的 § 10 评审记录。
- 04 喂回执行模型： 阅读 herdr 右侧分屏中 opus 的评审意见。
- 05 收敛后才动手 —— **拍板的是人。**

Three rules

01 别让写的人自己审。

自评看不见证据层的错 —— 那条错误对它来说也是「已确认的事实」。

02 评审员要更强、要不同，只花在不可逆的 5% 上。

便宜模型跑量，贵模型把关。别平均用力。

03 意见必须编号落盘。人是拍板的人。

S2-CL-01 → § 10 评审记录。可追溯，才收敛得下来。

Thanks

Q & A